

TEKNİK RAPOR

Global Daily Climate Data

Büyük Veri Analizine Giriş | Dr. Ayşe Gül Eker

Veri Seti	Kaggle — Global Daily Climate Data (#13) ~27,6M kayıt, 14 sütun
Hedef Değişken	avg_temp_c (Günlük Ortalama Sıcaklık — Regresyon)
Ekip	Canpolat (Docker/Kafka) • Rojda (Spark/EDA) • Beyda (ML/Dashboard)

1. Proje Mimarisi

Proje, büyük ölçekli iklim verisini gerçek zamanlı işleyebilmek amacıyla üretim ortamı yakın bir boru hattı (pipeline) üzerine inşa edilmiştir. Mimari beş katmandan oluşmaktadır: veri üretimi, akış işleme, depolama, analiz ve modelleme.

Teknoloji Seçimleri ve Gerekçeleri

Teknoloji	Kullanım Amacı	Entegrasyon Noktası
Apache Kafka	Gerçek zamanlı veri akışı	CSV Producer → Kafka topic → Spark consumer
Apache Spark (PySpark)	Dağıtık veri işleme	Streaming + batch: temizleme, özellik üretimi, ML
Delta Lake	ACID işlemler, sürüm yönetimi	Bronze / Silver / Gold katmanlı depolama
Spark MLlib + MLflow	Dağıtık ML, deney takibi	5 model eğitimi, metrik loglama, model kaydı
Docker Compose	Servis orkestrasyonu	Kafka, Zookeeper, Spark bağımsız çalışma ortamı
Matplotlib / Seaborn	Görselleştirme	EDA grafikleri ve dashboard çıktıları

Delta Lake Katmanlı Mimari

Veriler Delta Lake'in üç katmanlı (Medallion) mimarisinde saklanmaktadır. Bronze katmana Kafka'dan gelen ham kayıtlar olduğu gibi yazılmaktadır. Silver katmanda null değer temizleme ve tekrar eden kayıt eleme işlemleri uygulanmakta; böylece analiz kalitesi artırılmaktadır. Gold katmanda fiziksel tutarlılık filtreleri işletilmektedir: avg_temp_c değeri -60°C ile 60°C arasında olmalı, min_temp_c ≤ avg_temp_c ≤ max_temp_c koşulu sağlanmalıdır. Bu aşamada year/month sütunları da türetilmektedir; Gold katman, EDA ve ML süreçlerinin doğrudan giriş kaynağıdır.

Özellik Mühendisliği

Gold katmanı üzerinde altı yeni özellik türetilmiştir:

- temp_range — Günlük sıcaklık genliği (max_temp_c - min_temp_c)
- season_num — Mevsim kategorisinin sayısal kodlaması (0-3)
- rolling_avg_7 — İstasyon bazlı 7 günlük kayan ortalama sıcaklık
- is_extreme_temp — Aşırı sıcaklık bayrağı (>35°C veya <-20°C ise 1)
- prcp_category — Yağış miktarının kategorik sınıflandırması
- month — Mevcut tarih sütunundan çıkarılan ay bilgisi

2. Karşılaşılan Zorluklar ve Çözümler

Zorluk	Etki	Çözüm
Eksik ve gürültülü veriler	<i>Bazı istasyonlarda yüzde 60'ı aşan boş değer oranı (sunshine_total_min, snow_depth_mm)</i>	Silver katmanda dropna(subset=['avg_temp_c','station_id','date']); ML notebook'unda ayrıca dropna(subset=[TARGET_COL] + FEATURE_COLS) ile ikinci aşama filtreleme
Çok yüksek veri hacmi	<i>~27,6M kaydın Pandas ile işlenmesi bellek taşması riskine yol açıyordu</i>	Tüm dönüşümler PySpark DataFrame API'siyle yapıldı; sınırlı setlerde limit() kullanıldı
Kafka–Spark bağlantı sorunları	<i>Streaming başlangıcında broker bağlantı hataları ve offset tutarsızlıkları yaşandı</i>	docker-compose sağlık kontrolleri ile sıralama sağlandı; checkpoints dizini temizlendi
MLlib regParam=0 uyarısı	<i>LinearRegression ve GLR'de varsayılan regParam=0 nedeniyle sayısal kararsızlık uyarısı üretildi</i>	regParam değiştirilmedi; modeller yine de yakınsadı ve test $R^2=0.905$ ile makul sonuç verdi. Karşılaştırmalı regParam denemeleri iyileştirme olarak planlanmaktadır
Window fonksiyonu performansı	<i>7 günlük kayan ortalama istasyon başına sıralama gerektiriyor; büyük partition'larda yavaşlıyordu</i>	partitionBy('station_id').orderBy('date') ile Spark optimize edilmiş sıralama kullandı

3. Sonuçlar ve Değerlendirme

3.1 EDA Bulguları

EDA aşamasında ~15,9 milyon geçerli kayıt üzerinde analizler yürütülmüştür. Küresel günlük ortalama sıcaklık 14,87°C olarak ölçülmüştür. Yıllık trend grafiği, 1970'ten günümüze küresel sıcaklıklarda tutarlı bir artış eğilimini ortaya koymaktadır. Aylık ortalamalar, yaz aylarının (Haziran–Ağustos) kış aylarına kıyasla yaklaşık 12°C daha sıcak olduğunu göstermektedir. Korelasyon matrisi incelendiğinde min_temp_c ve max_temp_c değişkenlerinin hedef değişkenle (avg_temp_c) en güçlü ilişkiyi sergilediği görülmektedir. Yağış ile sıcaklık arasındaki ilişki mevsimsel bağımlılık göstermekte; kış aylarında bu iki değişken arasında negatif bir korelasyon gözlemlenmektedir. En sıcak 20 şehir analizi, Orta Afrika ve Güneydoğu Asya lokasyonlarının üst sıralarda yer aldığını ortaya koymuştur.

3.2 ML Model Karşılaştırması

Beş farklı Spark MLlib regresyon modeli MLflow ile izlenerek eğitilmiş ve test seti üzerinde değerlendirilmiştir. Modeller yalnızca türetilmiş özellikler üzerinde çalışmıştır: temp_range, month, season_num, rolling_avg_7, is_extreme_temp, prcp_category, avg_wind_speed_kmh, avg_sea_level_pres_hpa, sunshine_total_min. Ham sıcaklık sütunları (min_temp_c, max_temp_c) modele verilmemiştir. Tüm metrikler aşağıda özetlenmiştir:

Model	RMSE (°C)	MAE (°C)	R^2
Gradient Boosted Trees (GBT) ★	2.9077	2.2113	0.9089
Linear Regression	2.9714	2.2700	0.9049
Generalized Linear Regression	2.9714	2.2700	0.9049

Decision Tree	3.1030	2.3579	0.8963
Random Forest	3.5129	2.7184	0.8670

★ En iyi model — MLflow'a kayıt edildi

3.3 Genel Değerlendirme

En yüksek performansa sahip model Gradient Boosted Trees (GBT) olmuştur (RMSE=2.91°C, $R^2=0.909$). Bu sonuç, modelin hedef değişkendeki varyansın yaklaşık yüzde 91'ini açıkladığını göstermektedir. Lineer modeller (LR ve GLR) neredeyse özdeş sonuçlar üretmiş; bu durum veri setinde güçlü doğrusal ilişkilerin de varlığına işaret etmektedir. Random Forest modelinin diğer yöntemler karşısında görece düşük kalması, muhtemelen varsayılan ağaç derinliği ve örnekleme parametrelerinden kaynaklanmaktadır; hiperparametre optimizasyonu ile iyileştirme potansiyeli mevcuttur.

Özellik önem analizi (RandomForest feature importances), rolling_avg_7 (7 günlük kayan ortalama) ve season_num değişkenlerinin model tahmin gücüne en büyük katkıyı sağladığını ortaya koymuştur. temp_range ve season_num değişkenleri de anlamlı katkı sunmuştur. Tüm deney sonuçları MLflow arayüzü üzerinden izlenebilir ve yeniden üretilebilir durumdadır. Proje, Kafka'dan Delta Lake'e ve MLflow'a uzanan uçtan uca büyük veri yaşam döngüsünü başarıyla hayata geçirmiştir.